



预备知识——概率表示与计算

概率理论(PROBABILITY THEORY)

- 机器人的观测和执行受噪声和扰动影响存在很多不确定性
- 概率理论为不确定性的量化和计算提供了一个一致的框架



基本定义

- 随机变量 Y (random variable):

有概率输出的一个事件的名字，它的值为事件的输出结果

$p(Y = y_i)$ ， y_i 为变量 Y 的取值， $p(Y = y_i)$ 为变量 Y 取值为 y_i 的概率

- 随机变量 Y 的概率分布 (probability distribution) :

描述了取值为任一可能值 y_i 的可能性 $p(Y = y_i)$

$$p(Y = y_i) \geq 0$$

$$\sum_i p(Y = y_i) = 1$$



基本定义

- 两个随机变量 X, Y 的联合概率(Joint probability):

$$p(X = x_i, Y = y_i)$$


- 条件概率(Conditional probability):

$$p(Y = y_i | X = x_i)$$

基本概率计算

Sum rule of probability (和规则)

$$p(X = x_i) = \sum_j p(X = x_i, Y = y_j)$$



Product rule of probability (乘法规则)

$$p(X = x_i, Y = y_j) = p(Y = y_j | X = x_i) p(X = x_i)$$

如果 X, Y 相互独立, 则 $p(X = x_i, Y = y_j) = p(Y = y_j)p(X = x_i)$



基本概率计算

Bayes' theorem (贝叶斯规则)

$$p(X|Y) = \frac{p(Y|X)p(X)}{p(Y)}$$



$$p(X, Y) = p(Y|X)p(X) \quad p(Y, X) = p(X|Y)p(Y) \quad p(X, Y) = p(Y, X)$$

$$p(Y) = \sum_X p(X, Y) = \sum_X p(Y|X)p(X) \Rightarrow p(X|Y) = \frac{p(Y|X)p(X)}{\sum_X p(Y|X)p(X)}$$



$$p(X|Y) = \eta p(Y|X)p(X)$$


η 为归一化因子



基本概率知识

Bayes' theorem (贝叶斯规则)

$$p(X|Y) = \eta p(Y|X)p(X)$$



基本概率知识

Bayes' theorem (贝叶斯规则)


$$p(X|Y) = \eta p(Y|X)p(X)$$

$$posterior \propto likelihood \times prior$$

根据观测可能性将先验概率转化为后验概率

概率密度 (PROBABILITY DENSITIES)

- 实值变量 x 的概率通过概率密度 $p(x)$ 定义,
表示 x 落在区间 $(x, x + \delta x)$ 内的概率为 $p(x)\delta x$, $\delta x \rightarrow 0$



$$p(x) > 0$$

$$\int_{-\infty}^{\infty} p(x) dx = 1$$

$$p(x \in (a, b)) = \int_a^b p(x) dx$$



概率密度计算规则

- 和规则

$$p(x) = \int p(x, y) dy$$

- 乘法规则

$$p(x, y) = p(y|x)p(x)$$

- 贝叶斯规则

$$p(x|y) = \eta p(y|x)p(x)$$



向量的概率密度

$$\mathbf{x} = (x_1, x_2, \dots, x_N)$$

$$p(\mathbf{x}) = p(x_1, x_2, \dots, x_N) \quad \text{联合概率密度}$$

表示 $\mathbf{x}$ 落在无穷小体积 $\delta\mathbf{x}$ 内的概率为 $p(\mathbf{x})\delta\mathbf{x}$

同样，多变量概率密度必须满足

$$p(\mathbf{x}) > 0$$

$$\int_{-\infty}^{\infty} p(\mathbf{x}) d\mathbf{x} = 1$$



期望 (EXPECTATION)

○ 期望: 函数 $f(x)$ 在概率分布 $p(x)$ 下的平均值, 记为 $E[f]$

- 对于离散分布

$$E[f] = \sum_x p(x)f(x)$$

- 对于连续分布

$$E[f] = \int p(x)f(x)dx$$

○ 近似期望(approximate expectation)

通过一组粒子分布近似表示概率分布,
某区域内粒子分布越密集, 真实状态
落在该区域的可能性越大

$$E[f] \approx \frac{1}{N} \sum_{n=1}^N f(x_n)$$



随机变量 x 的期望值（均值）

- 离散分布

$$E[x] = \sum_x p(x)x$$

- 连续分布

$$E[x] = \int p(x)x dx$$



随机变量的方差(VARIANCE)与协方差(COVARIANCE)

- 方差：随机变量的离散程度，与期望的差异

$$\text{var}[x] = E[(x - E(x))^2] = E[x^2] - E[x]^2$$

- 协方差：两个随机变量的总体误差

$$\text{cov}[x, y] = E_{xy}[\{x - E(x)\}\{y - E(y)\}]$$

$$= E_{xy}[xy] - E[x]E[y]$$


(如果 x, y 相互独立，他们之间的协方差为0)



高斯分布(GAUSSIAN DISTRIBUTION)

- 也称为正态分布(Normal distribution)
- 对于单实变量 x ，其高斯分布为

$$N(x; \mu, \sigma^2) = \frac{1}{(2\pi\sigma^2)^{1/2}} \exp\left\{-\frac{1}{2\sigma^2} (x - \mu)^2\right\}$$




μ : 均值

σ : 标准偏差

σ^2 : 方差

$\beta = 1/\sigma^2$: 精度

高斯分布



$$p(|x - \mu| \leq \sigma) \approx 0.68$$

$$p(|x - \mu| \leq 2\sigma) \approx 0.95$$

$$p(|x - \mu| \leq 3\sigma) \approx 0.997$$

多变量高斯分布

$$\mathbf{x} = (x_1, x_2, \dots, x_N)^T$$

$$N(\mathbf{x}; \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{N/2}} \frac{1}{|\boldsymbol{\Sigma}|^{1/2}} \exp\left\{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right\}$$



$$\boldsymbol{\mu} = E[\mathbf{x}] = (E[x_1], E[x_2], \dots, E[x_N])^T \quad N\text{维均值向量}$$

$$\boldsymbol{\Sigma} = E[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T] \quad N \times N \text{ 维协方差矩阵} \quad |\boldsymbol{\Sigma}|: \boldsymbol{\Sigma} \text{ 的行列式}$$

$$= \begin{pmatrix} P_{11} & P_{12} & \dots & P_{1N} \\ P_{21} & P_{22} & \dots & P_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ P_{N1} & P_{N2} & \dots & P_{NN} \end{pmatrix}$$



二维高斯分布



最大后验概率估计MAP与最大似然估计MLE

- 对一个状态进行最优估计，可以采用使得在该状态下后验概率最大化的方法，称为MAP(Maximize a Posterior)

$$x^*_{MAP} = \operatorname{argmax} P(x|z) = \operatorname{argmax} P(z|x)P(x)$$

- 如果没有先验，可以求解其最大似然估计(MLE, Maximize Likelihood Estimation)

$$x^*_{MLE} = \operatorname{argmax} P(z|x)$$


在什么样的状态下最可能产生现在观测到的数据

基于MLE的高斯分布参数估计

记标量变量 x 的 N 次观测为 $\bar{x} = (x_1, x_2, \dots, x_N)^T$

这些观测数据相互独立，分布服从高斯分布 $N(x; \mu, \sigma^2)$

高斯分布参数估计： $(\mu, \sigma^2) = \operatorname{argmax} P(\bar{x} | \mu, \sigma^2)$



$$P(\bar{x} | \mu, \sigma^2) = \prod_{n=1}^N p(x_n | \mu, \sigma^2) = \prod_{n=1}^N N(x_n; \mu, \sigma^2)$$

基于MLE的高斯分布参数估计


○ Maximum likelihood → Maximum log likelihood

$$\log p(\bar{\mathbf{x}} | \mu, \sigma^2) = -\frac{1}{2\sigma^2} \sum_{n=1}^N (x_n - \mu)^2 - \frac{N}{2} \log \sigma^2 - \frac{N}{2} \log(2\pi)$$

$$\frac{\partial \log p(\bar{\mathbf{x}} | \mu, \sigma^2)}{\partial \mu} = 0 \quad \rightarrow \quad \mu_{ML} = \frac{1}{N} \sum_{n=1}^N x_n$$

$$\frac{\partial \log p(\bar{\mathbf{x}} | \mu, \sigma^2)}{\partial \sigma^2} = 0 \quad \rightarrow \quad \sigma_{ML}^2 = \frac{1}{N} \sum_{n=1}^N (x_n - \mu_{ML})^2$$






第六讲 定位

熊蓉

浙江大学控制科学与工程学院

定位问题

- 估计机器人在世界/全局坐标系中的位置/位姿



定位方法



基于外部设备感知的定位

基于里程估计的航位推算

基于本体观测的定位估计

运动与观测融合的自我定位



需要地图



6.1 地图表示形式

地图表示形式与定位/导航方法相互关联

- 地图需有效表达环境信息，支撑定位/导航
 - 根据地图中所记录障碍物位置，**规划**机器人从当前点到目标点的可行路径
 - 通过实时感知和地图信息的匹配，**定位**移动机器人在环境中的位置



地图表示形式也受传感器数据类型影响


○ 常用传感器



主要地图表示形式

- 点云地图
- 栅格地图
- 特征地图
- 拓扑地图

1. 点云地图 (POINT CLOUD)




- 由空间中障碍物边缘点集合构成
- Point Cloud = a “cloud” (i.e., collection) of n points

$$M = \{p_1, p_2, \dots, p_n\} \quad p_i = (x_i, y_i)^T \text{ 或 } p_i = (x_i, y_i, z_i)^T$$

激光测距仪、深度相机、相机等传感器均可用于构建点云地图


采用二维激光测距仪获得的点云地图



可直接获得局部点云地图，通过SLAM构建全局点云地图



采用三维激光测距仪获得的点云地图



可直接获得局部点云地图，结合SLAM构建全局点云地图


采用RGBD传感器获得的点云地图



可直接获得具有RGB信息的局部点云地图，数据具有稠密特性




采用摄像头构建的点云地图



需对图像进行处理，直接双目匹配恢复匹配点视深，形成视觉像素点云，或者提取特征后估计特征空间位置，形成视觉特征点云，具有稀疏特性

多信息点云地图



空间坐标+颜色纹理

激光测距仪+视觉


RGBD传感器

法向量、梯度等信息

通过相邻点计算




多信息点云地图



有助于点云的分割分类



多信息点云地图






对于移动机器人，可提取可行区域，进行导航规划



1. 点云地图(PPOINT CLOUD)

○ 优点:

- 完全表示环境三维信息
- 所构建地图不需要预先定义尺寸
- 可方便地利用ICP等匹配方法进行里程估计和定位



1. 点云地图(PPOINT CLOUD)

○ 缺点:

- 存储要求高





16通道三维点云
数据有30万点/秒



1. 点云地图(PPOINT CLOUD)


○ 缺点:

- 存储要求高
- 环境描述层次低，未区分所测量物体是道路还是障碍物，也没有说明点与点之间的空间是空闲、被占还是未知，需处理后才能应用于导航



2. 栅格地图

- 也称为占用栅格地图(Occupied Grid Map)
- 基本思想：将环境分解成一系列离散栅格，每个栅格有一个值，表示该栅格被障碍物占用的情况




地图表示为 $M = \{m_1, m_2, \dots, m_n\}$

m_i : 地图中第 i 个栅格被占情况，取值0或1

2. 栅格地图

- 也称为占用栅格地图(Occupied Grid Map)
- 基本思想：将环境分解成一系列离散栅格，每个栅格有一个值，表示该栅格被障碍物占用的情况



地图表示为 $M = \{m_1, m_2, \dots, m_n\}$

m_i : 地图中第 i 个栅格被占情况，取值0或1

概率架构下，栅格存储值为 $p(m_i = 1)$


表示栅格单元被障碍物占用的可能性

通常简写为 $p(m_i)$

2. 栅格地图



二维栅格地图



三维栅格地图





2. 栅格地图

- 主要采用激光测距仪数据来构建
- 优点：
 - 是一种几何度量地图，可以详细描述环境信息
 - 可以方便地采用A*等搜索算法进行最优路径规划
 - 可以方便地根据栅格被占概率计算获得当前观测的可能性，实现定位估计
- 缺点：
 - 由于地图存储空间由所需建图的环境范围和栅格的分辨率确定，因此随着栅格数量的增加和环境的扩大，地图所需内存和维护时间也迅速增长，地图维度的增加更会随着环境的扩大造成空间需求呈指数级增长



栅格地图降低存储空间的方法：采用四叉树/八叉树表示

- 通过分辨率可变来减少存储空间需求




栅格地图降低存储空间的方法：采用四叉树/八叉树表示

- 通过分辨率可变来减少存储空间需求




栅格地图降低存储空间的方法：采用四叉树/八叉树表示

- 通过分辨率可变来减少存储空间需求



71,000扫描点




12,000节点




栅格地图降低存储空间的方法：采用四叉树/八叉树表示


- 通过分辨率可变来减少存储空间需求
- 通过限制查询的深度，可以随时获得同一地图的多个分辨率




点云地图



八叉树地图
体素分辨率为0.08m



查询不同深度获得的八叉树地图
体素分辨率分别为0.64 m和1.28 m




栅格地图降低存储空间的方法：采用四叉树/八叉树表示

- 通过分辨率可变来减少存储空间需求
- 通过限制查询的深度，可以随时获得同一地图的多个分辨率
- 随着观测的获取增量式更新观测区域的地图，从而不需要预先定义地图的大小，避免了未知区域占用存储空间


存在问题：实现复杂（存储结构、更新方法，地图文件...）

高度栅格地图(ELEVATION MAP)

- 针对问题：实现不平整地面上的高效导航规划
 - 二维栅格地图只能表示某个平面的环境信息，无法表示不平整地面
 - 三维栅格地图对存储资源和计算时间要求高，八叉树实现复杂





高度栅格地图(ELEVATION MAP)




高度栅格地图(ELEVATION MAP)

- 基本思路：采用二维栅格地图表示方法，在每个栅格中存储该栅格内障碍物的高度信息，通过高斯分布来表示高度估计和不确定性
- 也称为2.5维占用栅格地图



高度栅格地图(ELEVATION MAP)

- 基本思路：采用二维栅格地图表示方法，在每个栅格中存储该栅格内障碍物的高度信息，通过高斯分布来表示高度估计和不确定性




高度估计的不确定性随着观测距离变大而变大



3. 特征地图

- 基本思想：以抽象的特征描述环境，通常采用拟合障碍物的陆标、线段、平面、多边形等结构性几何特征，通过一组参数对特征进行建模




陆标特征地图



线段特征地图

3. 特征地图

- 基本思想：以抽象的特征描述环境，通常采用拟合障碍物的陆标、线段、平面、多边形等结构性几何特征，通过一组参数对特征进行建模



陆标特征地图

陆标描述方法：

$N(u, \Sigma)$ (高斯分布)

$u = (x, y, s)^T$ 为估计均值


(x, y) 为陆标平面坐标

s 为特征标识，用于匹配

Σ 为方差，表示估计不确定性

3. 特征地图

- 实际应用时，需通过传感器信息处理来构建陆标特征





悉尼大学野外机器人研究中心

Victoria park data set

采用聚类方法从激光测距仪数据中提取
得到树干，作为陆标特征

3. 特征地图


- 有些应用采用人工放置特定陆标的方法



悉尼大学野外机器人研究中心水下探测

3. 特征地图

- 发展趋势1: 从二维特征向三维特征发展




3D planar feature

Figure courtesy of Alexander J. B. Trevor

3. 特征地图

- 发展趋势2: 提升环境描述的层次



3. 特征地图

○ 优点


- 简洁、紧凑、内存占用量小
- 表示方式更接近人对环境的感知
- 对环境具有更高层次的描述性，使定位与建图的鲁棒性更强

○ 缺点


- 无法精确表征复杂的真实环境
- 不能表示环境被占用/空闲/未知情况，不能直接用于导航规划

4. 拓扑地图(TOPOLOGICAL MAP)

- 基本思想：把环境表示为带结点和相关连接线的拓扑结构图，其中结点表示环境中的重要位置点，边表示结点间的连接关系
- 优点：
 - 易于扩展，可以实现快速路径规划
- 缺点：
 - 由于信息的抽象性，使得机器人难以实现精确可靠的自定位




地图表示研究趋势1: 混合地图表示/多层地图表示



视觉点云地图和线段特征地图混合



地图表示研究趋势1: 混合地图表示/多层地图表示




拓扑地图与视觉点云地图结合



地图表示研究趋势2: 语义地图


- 语义地图是除了环境的空间信息之外还包含已知类别的实体特征的地图。这些实体的信息独立于地图内容，可用于一些特定知识背景中的推理



可使传统路径规划转化为面向任务的规划，提高人机交互性能

地图表示研究趋势2: 语义地图


- 语义地图的载体可以是前述各种地图表示形式，除了传统地图的基本属性外，地图的每个组成单元还包含该单元对应的语义信息



地图表示研究趋势2: 语义地图

- 语义地图的载体可以是前述各种地图表示形式，除了传统地图的基本属性外，地图的每个组成单元还包含该单元对应的语义信息





6.2 基于本体观测的定位估计

定位方法



基于外部设备感知的定位

基于里程估计的航位推算

基于本体观测的定位估计

运动与观测融合的自我定位

需要地图

基于本体观测的定位估计

- 基本思想：利用本体传感器获得的环境观测信息与地图中存储的各个位置上的信息进行匹配，实现位置/位姿识别，也成为地点识别
- 具体方法：
 - 基于人工定义独特标识的定位
 - 多个非独特标识感知融合定位
 - 激光/视觉感知信息匹配定位

采用人工定义独特标识的定位

- 在环境中部署特殊标签，降低成本，确保可靠性





地面二维码




多个非独特标识感知融合定位

- 在环境中部署一定标识，标识之间不具备独特性，利用3个以上标识感知信息进行定位估计

安装在某一高度的激光反射板



多个非独特标识感知融合定位





定位原理：计算在每个位置上
得到观测的可能性


具体见 6.5 观测模型



激光感知信息匹配下的定位/地点识别




激光感知信息匹配下的定位/地点识别



基于本体观测的定位估计

- 位置信息需具备可鉴别性，否则需要正确的数据关联
 - 对于采用人工标识，面临实际应用中存在被破坏、污染等风险
 - 对于采用激光/视觉信息，面临环境动态变化和不同位置相似等为数据关联带来的挑战
- 地图位置节点密度会影响定位的准确性、鲁棒性、和计算效率
- 存储大规模环境的激光/视觉信息需要较大的存储空间，匹配耗时



6.3 运动和观测信息融合的自定位

运动和观测信息融合的自定位

- 定义：在给定环境地图的条件下，根据机器人的**运动控制/里程估计**信息和机器人对环境的**观测**信息，估计机器人在环境地图中的坐标



运动和观测信息融合的自定位

- 简单方法：有观测时根据观测匹配定位，无观测时根据里程估计进行航位推算



观测到二维码时可确定定位，没有观测到二维码时利用里程估计航位推算



根据观测匹配进行地点识别，没有观测/无法匹配时利用里程估计航位推算

运动和观测信息融合的自定位

- 简单方法：有观测时根据观测匹配定位，无观测时根据里程估计进行航位推算
- 存在问题：
 - 观测存在不确定性，里程估计也存在不确定性，如何融合
 - 观测到多个特征时，每个特征观测都存在不确定性，如何融合估计
- 解决方案：
 - 对不确定性进行描述（称为置信度），在概率架构下进行融合
 - 用方差表示置信度，方差小表示置信度高
 - 控制感知信息融合的自定位就是利用里程估计和观测信息估计方差最小下的机器人位姿

自定位问题概率描述

- 问题定义为最优估计问题，最优估计的一个体现是估计的方差很小
- 贝叶斯估计器是一种最小方差估计器
- 问题的概率描述：

记地图为 m ,

t 时刻机器人位姿为 $\mathbf{x}_t = (x_t, y_t, \theta_t)^T$ ，观测信息为 z_t ，控制信息为 $\mathbf{u}_t$

$$\mathbf{X}^t = \{\mathbf{x}_0, \mathbf{x}_1, \dots, \mathbf{x}_t\} \quad \mathbf{Z}^t = \{z_0, z_1, \dots, z_t\} \quad \mathbf{U}^{t-1} = \{\mathbf{u}_0, \mathbf{u}_1, \dots, \mathbf{u}_{t-1}\}$$

$$\text{求 } \hat{\mathbf{X}}^t \triangleq E[\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, m]$$

$$E[\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, m] = \int \boxed{p(\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, m)} \mathbf{X}^t d\mathbf{X}^t$$

构建递推算式

$$p(\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) = p(\mathbf{X}^{t-1}, \mathbf{x}_t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m})$$



根据乘法规则 $p(X, Y) = p(Y | X)p(X)$

$$p(\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) = p(\mathbf{x}_t | \mathbf{X}^{t-1}, \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{X}^{t-1} | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m})$$



t-1时刻的路径与之后的观测和控制无关

$$p(\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) = p(\mathbf{x}_t | \mathbf{X}^{t-1}, \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{X}^{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m})$$



根据贝叶斯公式 $p(Y | X) = \eta p(X | Y)p(Y)$

$$p(\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m})$$

$$= \eta p(\mathbf{z}_t | \mathbf{X}^t, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{x}_t | \mathbf{X}^{t-1}, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{X}^{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m})$$

$$\begin{aligned}
 & p(\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) \\
 &= \eta p(\mathbf{z}_t | \mathbf{X}^t, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{x}_t | \mathbf{X}^{t-1}, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{X}^{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m})
 \end{aligned}$$

当前的状态可由上一时刻状态和控制量完全确定，即在 $\mathbf{x}_{t-1}, \mathbf{u}_{t-1}$ 已知情况下， $\mathbf{x}_t$ 和其他变量独立

$$p(\mathbf{x}_t | \mathbf{X}^{t-1}, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) = p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m})$$

当前的观测可由当前状态完全确定，即在 $\mathbf{x}_t$ 已知情况下， $\mathbf{z}_t$ 和其他变量独立

$$p(\mathbf{z}_t | \mathbf{X}^t, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) = p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m})$$

$$p(\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m})$$

$$= \eta p(\mathbf{z}_t | \mathbf{X}^t, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{x}_t | \mathbf{X}^{t-1}, \mathbf{Z}^{t-1}, \mathbf{U}^{t-1}, \mathbf{m}) p(\mathbf{X}^{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m})$$



$$p(\mathbf{X}_t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) = \eta p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) p(\mathbf{X}_{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m})$$



t时刻后验



观测模型



运动模型



t-1时刻后验



在实际应用中，自定位问题 $\hat{\mathbf{X}}^t \triangleq E[\mathbf{X}^t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}]$

通常简化为 $\mathbf{x}_t = E[\mathbf{x}_t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}]$

$$\begin{aligned} & p(\mathbf{x}_t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) \\ &= \eta p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) \int p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) p(\mathbf{x}_{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m}) d\mathbf{x}_{t-1} \end{aligned}$$

实时自定位贝叶斯递推公式


Markov Localization 马尔可夫定位



自定位问题分类

- 按初始和运行时的可用信息
 - 位置跟踪（position tracking）：
 - 机器人初始位置已知，需要解决对里程计累积误差的补偿
 - 全局定位（global localization）：
 - 机器人初始位置未知
 - 绑架问题（kidnapped robot problem）：
 - 机器人在定位良好的条件下突然被移到另一个未被告知的地方
 - 与全局定位问题的差异在于，当机器人被绑架时，机器人可能已经对自己所在的位置非常确信了
 - 用于检测定位算法发现错误并从错误中恢复的能力


MARKOV LOCALIZATION



$$\begin{aligned} p(\mathbf{x}_0 \mid \mathbf{Z}^0, \mathbf{m}) \\ &= p(\mathbf{x}_0 \mid \mathbf{z}_0, \mathbf{m}) \\ &= \eta p(\mathbf{z}_0 \mid \mathbf{x}_0, \mathbf{m}) p(\mathbf{x}_0) \end{aligned}$$



MARKOV LOCALIZATION




$$p(\mathbf{x}_0) = ?$$

- 如果初始位姿已知 → 位置跟踪问题

$$p(\mathbf{x}_0) = \begin{cases} 1 & \mathbf{x}_0 = \bar{\mathbf{x}}_0 (\text{已知的初始位置}) \\ 0 & \text{others} \end{cases}$$



MARKOV LOCALIZATION




$$p(\mathbf{x}_0) = ?$$


- 如果初始位姿未知 → 全局定位问题


$$p(\mathbf{x}_0) = \frac{1}{|X|} \quad |X| \text{ 为地图中所有位姿的空间大小}$$



$$p(\mathbf{z}_0 | \mathbf{x}_0, \mathbf{m}) = ?$$







6.4 概率表示下的运动模型

运动模型

$$\begin{aligned} p(\mathbf{x}_t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) \\ = \eta p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) \int p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) p(\mathbf{x}_{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m}) d\mathbf{x}_{t-1} \end{aligned}$$

利用贝叶斯规则

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) = \eta p(\mathbf{m} | \mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$



运动模型

$$p(\mathbf{x}_t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) \\ = \eta p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) \int p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) p(\mathbf{x}_{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m}) d\mathbf{x}_{t-1}$$

利用贝叶斯规则

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) = \eta p(\mathbf{m} | \mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$

给定上一时刻位姿 $\mathbf{x}_{t-1}$ 和控制指令 $\mathbf{u}_{t-1}$,
计算当前位姿 $\mathbf{x}_t$ 的概率分布

运动模型

$$p(\mathbf{x}_t | \mathbf{Z}^t, \mathbf{U}^{t-1}, \mathbf{m}) \\ = \eta p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) \int p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) p(\mathbf{x}_{t-1} | \mathbf{Z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m}) d\mathbf{x}_{t-1}$$

利用贝叶斯规则

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) = \eta p(\mathbf{m} | \mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$

在控制指令 $\mathbf{u}_{t-1}$ 下机器人从 $\mathbf{x}_{t-1}$ 移动到 $\mathbf{x}_t$ ，在这样条件下地图 $\mathbf{m}$ 的可能性

如果路径或者 $\mathbf{x}_t$ 与环境障碍物碰撞，则获得地图 $\mathbf{m}$ 的可能性低



通过路径验证地图存在的可能性实现地图条件下当前位姿估计的验证

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$

给定上一时刻位姿 $\mathbf{x}_{t-1}$ 和控制指令 $\mathbf{u}_{t-1}$ ，计算当前位姿 $\mathbf{x}_t$ 的概率分布

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$

二维投影




$$p(\mathbf{x}_t \mid \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$

- 不同的控制指令形成不同的概率运动模型
- 速度运动模型
 - $\mathbf{u}_{t-1}$ 为发送给机器人、控制机器人运动的指令
- 里程计运动模型
 - $\mathbf{u}_{t-1}$ 为里程计数据

如何求解概率运动模型？

里程计运动模型

- 无噪声情况下根据里程计的航位推算模型



将运动变化量叠加到 $\mathbf{x}_{t-1}$ 得到 $\mathbf{x}_t$

$$\begin{pmatrix} x' \\ y' \\ \theta' \end{pmatrix} = \begin{pmatrix} x + \delta_{trans} \cos(\theta + \delta_{rot1}) \\ y + \delta_{trans} \sin(\theta + \delta_{rot1}) \\ \theta + \delta_{rot1} + \delta_{rot2} \end{pmatrix}$$

根据该模型的逆模型，可以得到 $\mathbf{x}_{t-1}$ 到 $\mathbf{x}_t$ 的里程值, 该值为真实值

里程计运动模型

- 实际测量中带有各种误差


真实值 = 测量值 - 误差

$$\hat{\delta}_{rot1} = \delta_{rot1} - \tilde{\delta}_{rot1}, \hat{\delta}_{trans} = \delta_{trans} - \tilde{\delta}_{trans}, \hat{\delta}_{rot2} = \delta_{rot2} - \tilde{\delta}_{rot2}$$

$$\begin{pmatrix} x' \\ y' \\ \theta' \end{pmatrix} = \begin{pmatrix} x + \hat{\delta}_{trans} \cos(\theta + \hat{\delta}_{rot1}) \\ y + \hat{\delta}_{trans} \sin(\theta + \hat{\delta}_{rot1}) \\ \theta + \hat{\delta}_{rot1} + \hat{\delta}_{rot2} \end{pmatrix}$$

里程计运动模型

- 可以设定误差为均值为0的高斯分布



真实值与测量值之间的误差
应服从该分布
误差越小，概率越高
误差越大，概率越低

里程计运动模型的概率分布 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$

○ 闭式求解

- (1) 将里程计数据 $\mathbf{u}_{t-1}$ 表示为 $\delta = (\delta_{rot1}, \delta_{trans}, \delta_{rot2})^T$ ，作为测量控制值
- (2) 根据 $\mathbf{x}_{t-1}, \mathbf{x}_t$ 计算机器人的实际运动变化量 $\hat{\delta} = (\hat{\delta}_{rot1}, \hat{\delta}_{trans}, \hat{\delta}_{rot2})^T$ ，作为真实控制值
- (3) 根据真实值与测量值之间误差 $\tilde{\delta} = \delta - \hat{\delta}$ 的分布估计 $\mathbf{x}_t$ 的分布

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) = p(\tilde{\delta}_{rot1}) \cdot p(\tilde{\delta}_{trans}) \cdot p(\tilde{\delta}_{rot2})$$


里程计运动模型中的误差模型

误差分布表示

$$p(\tilde{\delta}_{rot1}) = N(\tilde{\delta}_{rot1}; 0, \alpha_1 |\delta_{rot1}| + \alpha_2 |\delta_{trans}|)$$

$$p(\tilde{\delta}_{trans}) = N(\tilde{\delta}_{trans}; 0, \alpha_3 |\delta_{trans}| + \alpha_4 |\delta_{rot1} + \delta_{rot2}|)$$


$$p(\tilde{\delta}_{rot2}) = N(\tilde{\delta}_{rot2}; 0, \alpha_1 |\delta_{rot2}| + \alpha_2 |\delta_{trans}|)$$



里程计运动模型的概率分布 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$

○ 闭式求解

不同 α_i 参数下得到的 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$



里程计运动模型的概率分布 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$

○ 随机采样求解

将噪声建模为高斯分布

- 在噪声的高斯分布中随机采样

$$\tilde{\delta}_{rot1} = \text{sample}(\alpha_1|\delta_{rot1}| + \alpha_2|\delta_{trans}|), \tilde{\delta}_{trans} = \dots, \tilde{\delta}_{rot2} = \dots$$

- 基于采样得到的噪声和测量得到的里程计值，构建机器人实际执行的控制指令


$$\hat{\delta}_{rot1} = \delta_{rot1} - \tilde{\delta}_{rot1}, \hat{\delta}_{trans} = \delta_{trans} - \tilde{\delta}_{trans}, \hat{\delta}_{rot2} = \delta_{rot2} - \tilde{\delta}_{rot2}$$

- 利用前述里程运动叠加模型计算 $\mathbf{x}_t$
- 重复上述过程，所得 $\mathbf{x}_t$ 点集合构成对 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$ 的描述

里程计运动模型的概率分布 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$

随机采样求解

不同 α_i 参数下得到的 $p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$



每个子图含500个样本



运动模型

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) = \eta p(\mathbf{m} | \mathbf{x}_t, \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$



地图分为可通行和不可通行

本项作用：基于地图降低运动模型的不确定性

问题：需要融合两次位姿之间路径不被占用的可能性和机器人根据控制跟随该路径的可能性，计算非常复杂，难以计算闭式解

实际应用时，可以


$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) \approx p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1})$$

$$p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) \approx \eta p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}) p(\mathbf{x}_t | \mathbf{m})$$


$$(a) p(x_t \mid u_t, x_{t-1})$$



$$(b) p(x_t \mid u_t, x_{t-1}, m)$$




$$\int p(\mathbf{x}_t | \mathbf{x}_{t-1}, \mathbf{u}_{t-1}, \mathbf{m}) p(\mathbf{x}_{t-1} | \mathbf{z}^{t-1}, \mathbf{U}^{t-2}, \mathbf{m}) d\mathbf{x}_{t-1}$$



如果只考虑运动模型进行位姿估计，其不确定性（方差）会不断地无上限增大






6.5 概率表示下的观测模型

观测模型 $p(z_t | x_t, m)$

$$p(x_t | Z^t, U^{t-1}, m) \\ = \eta p(z_t | x_t, m) \int p(x_t | x_{t-1}, u_{t-1}, m) p(x_{t-1} | Z^{t-1}, U^{t-2}, m) dx_{t-1}$$



观测模型 $p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m})$

- **观测模型**根据**感知测量模型**（即感知随机变量在取值范围内的概率分布/概率密度）确定位姿空间上得到观测的概率


感知测量模型：

描述测量信息的概率分布

观测模型：

描述在机器人位姿条件下得到测量信息的概率分布

特征的观测模型构建



$m_1 = (m_{1x}, m_{1y})$ 为地图中特征位置信息
(确定信息)

$\mathbf{z}_t = \{(r_j, \varphi_j)\}$ 为感知到的特征的测量信息
(带有测量误差)


特征的感知测量模型:

描述测量信息 (r_j, φ_j) 的概率分布

特征的观测模型:

描述在机器人位姿 $\mathbf{x}_t$ 条件下得到测量
信息 $\mathbf{z}_t$ 的概率分布

特征的观测模型构建



从感知测量模型到观测模型：

- 对所评估某位姿 x_t ，利用地图中特征确切位置，可以计算得到准确测量数据
- 实际测量值=真实值+误差
- 可以对误差分布进行建模（e. g. 均值为0的高斯分布），根据误差概率获得测量数据的概率，从而建立测量数据的概率描述

特征的观测模型构建计算示例



陆标特征地图表示

$$\mathbf{m} = \{\mathbf{m}_1, \mathbf{m}_2, \dots, \mathbf{m}_N\}$$

$\mathbf{m}_i$ 在地图中的坐标为

$$(m_{ix}, m_{iy})^T$$

t时刻的特征观测表示为 $\mathbf{z}_t = \{f_t^1, f_t^2, \dots, f_t^K\}$

$$f_t^i \triangleq (r_t^i, \varphi_t^i, s_t^i)^T$$

r_t^i : 特征与机器人之间的相对距离

φ_t^i : 特征与机器人之间的相对角度

s_t^i : 特征标识

特征的观测模型构建计算示例



假设特征观测条件独立

$$p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) = p(f_t^1, f_t^2, \dots, f_t^K | \mathbf{x}_t, \mathbf{m}) = \prod_{k=1}^K p(f_t^k | \mathbf{x}_t, \mathbf{m})$$

$$p(f_t^i | \mathbf{x}_t, \mathbf{m})$$

假设 f_t^i 对应的地图特征为 $\mathbf{m}_j$

将地图特征 $\mathbf{m}_j$ 转换到机器人坐标系下即为观测特征真值

$$\hat{\mathbf{f}}_t^i = \begin{pmatrix} \sqrt{(m_{jx} - x)^2 + (m_{jy} - y)^2} \\ \arctan 2(m_{jy} - y, m_{jx} - x) - \theta \\ s_j \end{pmatrix}$$


$$\mathbf{x}_t = (x, y, \theta)^T$$

测量值 = 真实值 + 误差

$$\mathbf{f}_t^i = \hat{\mathbf{f}}_t^i + \tilde{\delta}_f$$


根据观测误差模型, 则

$$p(f_t^i | \mathbf{x}_t, \mathbf{m}) = N(f_t^i; \hat{\mathbf{f}}_t^i, \sigma_f^2)$$




激光点云的观测模型 $p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m})$

$$p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m}) = \prod_{k=1}^K p(z_t^k | \mathbf{x}_t, \mathbf{m})$$




一个激光束的感知测量模型



激光点云的观测模型 $p(\mathbf{z}_t | \mathbf{x}_t, \mathbf{m})$



实际位姿与测量示意图




基于激光感知测量模型得到的观测模型




基于LIKELIHOOD FIELD的激光束观测模型



- 基本思想：
 - 把激光束末端投影于地图中
 - 根据激光束末端投影与地图中最近物体之间距离建模
 - 为减少在线计算量，根据地图离线构建Likelihood Field图



基于栅格地图的LIKELIHOOD FIELD建立

对于栅格地图中的每一个未占用栅格，搜索距离最近的占用栅格，计算高斯分布下的概率赋给该未占用栅格，最后给未知栅格赋值 $1 / z_{\max}$





END

